

Mejora de algoritmo de reconocimiento de emociones



Cecilia Jael Aguilar Aranda[†],
Alexander Espronceda Gómez[‡]
Satu Elisa Schaeffer

Posgrado en Ingeniería de Sistemas

[†]cjaelaguilar@gmail.com, [‡]alexeg98@gmail.com



Resumen

En este proyecto se busca incrementar el funcionamiento de un algoritmo de análisis de sentimientos en base a texto utilizando redes neuronales. Esto conlleva realizar modificaciones al código, así como el aumento del dataset con el que se trabaja. El objetivo es realizar un chatbot capaz de reconocer patrones, determinar el sentimiento mostrado por el usuario y actuar acorde a ello.

1. Introducción

El objetivo principal de este proyecto es llevar a cabo diversos procesos que ayuden a que un algoritmo de análisis de sentimientos por medio de texto tenga un porcentaje de acierto más alto. Esto se logrará mediante búsqueda, análisis y filtrado de datos relevantes, así como también la actualización del algoritmo que está siendo utilizado actualmente.

2. Antecedentes

El algoritmo de análisis de sentimientos por medio de texto que se utiliza en este proyecto le corresponde a Alexander Espronceda Gómez, quien actualmente está escribiendo un paper al respecto [1]. Por lo tanto, este proyecto solamente se enfoca en el mejoramiento de éste, y no en el proceso completo.




Figura 1: Gráfica representativa del porcentaje de acierto del algoritmo, antes de aplicársele alguna mejora

3. Estado de arte

En la actualidad existen muchos algoritmos complejos de análisis de sentimientos que funcionan sin necesidad de introducirle tantos datos, tales como GPT-3 (Generative Pre-trained Transformer 3). En donde gracias a su uso eficiente de transformadores y también gracias a que ha sido entrenado extensamente con datasets enormes (por ejemplo: Wikipedia Corpus, Common Crawl, WebText2, entre otros), no hay necesidad de encontrar datos tan específicos para entrenarlos [2].

Las opiniones son simples de entender para los humanos, pero, según Liu [3], para una computadora es necesario una noción con los siguientes elementos:

- **Objetivo** de la opinión: Entidades y sus características.
- **Sentimientos**: Positivos, negativos o neutrales
- **Poseedor** de la opinión
- **Tiempo** en el que las opiniones son expresadas.

También existen problemas relacionados al procesamiento de lenguaje natural (NLP). Dale [4] considera las siguientes las etapas del análisis de NLP:

- **Tokenización**: Convertir caracteres en palabras, símbolos u otros elementos llamados "tokens".
- **Análisis léxico**: Genera léxico y aplica etiquetas a los tokens.
- **Análisis sintáctico**: Proveer una estructura para cada oración.
- **Análisis semántico**: Encuentra el significado literal.
- **Análisis pragmático**: Determina el significado según el contexto.

La gran diferencia entre el algoritmo propuesto en este proyecto y algo más elaborado como lo es GPT-3, es el hecho de que este último no funciona localmente, sino que en realidad es una API por la cual tienes que pagar para poder usar, además de que OpenAI tiene completo control y regulación de los usos de su algoritmo [5].

Lo que se intenta hacer al momento de utilizar TensorFlow es darle el control completo al usuario en caso de que quiera darle sesgo a los datos o que lo adapte a las necesidades que tenga, sin necesidad de que pase a ser una caja negra. Éste proceso es bastante complicado y probablemente no se alcanzará el grado de porcentaje de acierto con el que cuenta GPT-3, pero se espera que sea lo suficiente como para poder ser una alternativa open-source viable.

4. Solución propuesta

La implementación se hizo en Python 3.7 [6], además de otras herramientas relacionadas con redes neuronales como Tensorflow 2.0.0 [7].

4.1 Metodología

Se comenzó por una búsqueda de datasets, utilizándose la librería NLTK [8] para filtrar palabras que no aportan mucho significado al texto.

Se consideró mejor un enfoque generalista debido a que las diferentes etiquetas de sentimiento a analizar no estaban distribuidas de manera uniforme; por lo que los datos se clasificaron únicamente en "Buena", "Neutral" y "Mala".

Se utilizó un algoritmo bidireccional STM con una activación de softmax de última capa. El léxico está limitado a 5000 elementos, y el largo máximo de cualquier frase después de ser filtrada es de 30 caracteres.

Ya después de ser actualizado, el dataset utilizado cuenta con alrededor de 60,000 tweets filtrados y clasificados.

Durante la fase de entrenamiento, se utilizaron 25 epochs con un 75 % del dataset en un orden arbitrario, usando el 25 % restante como validación.




Figura 2: Gráfica representativa del porcentaje de acierto del algoritmo, después de aplicársele las mejoras propuestas

5. Experimentos

Para determinar que este enfoque iba a funcionar, lo que hicimos fue correr varias veces el algoritmo con diferentes parámetros dentro de él, identificando áreas de oportunidad en donde podrían ir mejoras, y finalmente comparando resultados.

alex@AzathothReduz: ~/repos/Affective-Computing-VN/game	alex@AzathothReduz: ~/repos/Affective-Computing-VN/game
287/690 [=====] - ETA: 18s - loss: 0.5512 - accuracy: 0.776	365/780 [=====] - ETA: 11s - loss: 0.5207 - accuracy: 0.792
289/690 [=====] - ETA: 18s - loss: 0.5511 - accuracy: 0.776	367/780 [=====] - ETA: 11s - loss: 0.5197 - accuracy: 0.793
291/690 [=====] - ETA: 18s - loss: 0.5511 - accuracy: 0.776	369/780 [=====] - ETA: 10s - loss: 0.5197 - accuracy: 0.793
293/690 [=====] - ETA: 18s - loss: 0.5510 - accuracy: 0.776	371/780 [=====] - ETA: 10s - loss: 0.5200 - accuracy: 0.793
295/690 [=====] - ETA: 18s - loss: 0.5509 - accuracy: 0.776	373/780 [=====] - ETA: 10s - loss: 0.5200 - accuracy: 0.793
297/690 [=====] - ETA: 18s - loss: 0.5509 - accuracy: 0.777	375/780 [=====] - ETA: 10s - loss: 0.5218 - accuracy: 0.792
299/690 [=====] - ETA: 18s - loss: 0.5508 - accuracy: 0.777	377/780 [=====] - ETA: 10s - loss: 0.5220 - accuracy: 0.792
301/690 [=====] - ETA: 18s - loss: 0.5507 - accuracy: 0.777	379/780 [=====] - ETA: 10s - loss: 0.5218 - accuracy: 0.792
303/690 [=====] - ETA: 18s - loss: 0.5507 - accuracy: 0.777	381/780 [=====] - ETA: 10s - loss: 0.5225 - accuracy: 0.791
305/690 [=====] - ETA: 18s - loss: 0.5506 - accuracy: 0.777	383/780 [=====] - ETA: 10s - loss: 0.5216 - accuracy: 0.792
307/690 [=====] - ETA: 18s - loss: 0.5506 - accuracy: 0.777	385/780 [=====] - ETA: 10s - loss: 0.5223 - accuracy: 0.791
309/690 [=====] - ETA: 18s - loss: 0.5505 - accuracy: 0.777	387/780 [=====] - ETA: 10s - loss: 0.5221 - accuracy: 0.791
311/690 [=====] - ETA: 18s - loss: 0.5505 - accuracy: 0.777	389/780 [=====] - ETA: 10s - loss: 0.5226 - accuracy: 0.791
313/690 [=====] - ETA: 18s - loss: 0.5504 - accuracy: 0.777	391/780 [=====] - ETA: 10s - loss: 0.5225 - accuracy: 0.791
315/690 [=====] - ETA: 18s - loss: 0.5504 - accuracy: 0.777	393/780 [=====] - ETA: 10s - loss: 0.5242 - accuracy: 0.791
317/690 [=====] - ETA: 18s - loss: 0.5504 - accuracy: 0.777	395/780 [=====] - ETA: 10s - loss: 0.5231 - accuracy: 0.791
319/690 [=====] - ETA: 18s - loss: 0.5503 - accuracy: 0.777	397/780 [=====] - ETA: 10s - loss: 0.5234 - accuracy: 0.791
321/690 [=====] - ETA: 18s - loss: 0.5503 - accuracy: 0.777	399/780 [=====] - ETA: 10s - loss: 0.5227 - accuracy: 0.791
323/690 [=====] - ETA: 9s - loss: 0.5502 - accuracy: 0.7772	401/780 [=====] - ETA: 9s - loss: 0.5225 - accuracy: 0.7917
408/690 [=====] - ETA: 20s/stop - loss: 0.5475 - accuracy: 0.7772	403/780 [=====] - ETA: 19s/stop - loss: 0.5231 - accuracy: 0.7917
0.7790 - val_loss: 1.1243 - val_accuracy: 0.5592	0.7879 - val_loss: 1.0323 - val_accuracy: 0.5989
Training Accuracy: 0.8604	Training Accuracy: 0.8175
Testing Accuracy: 0.5592	Testing Accuracy: 0.5989
Write something: █	Write something: █

Figura 3: Parámetros antes y después de la mejora

6. Conclusiones

Se ha logrado un aumento en la precisión de reconocimiento de emociones, se espera realizar más modificaciones para mejorar el algoritmo y en un futuro implementarlo para su uso.

Agradecimientos Agradecemos a la dra. Elisa Schaeffer por su apoyo en la realización del póster, además de el PROVERICYT y Delfin al dar la oportunidad de participar en el Verano de Investigación Científica y Tecnológica 2021 y proporcionar una beca. El póster se preparó con <https://www.overleaf.com/>.

Referencias

- [1] Alexander Espronceda Gómez. Sentiment analysis through a chatbot. URL <https://github.com/Alex-Ego/Affective-Computing-VN>. A la fecha de redacción de este poster, éste paper sigue en proceso.
- [2] Amol Mavuduru. What is gpt-3 and why is it so powerful? *Towards Data Science*, 02 2021. URL <https://towardsdatascience.com/what-is-gpt-3-and-why-is-it-so-powerful-21e1ba59811>.
- [3] Bing Liu. Sentiment analysis: A multi-faceted problem. *IEEE Intell Syst*, 25, 01 2010.
- [4] R. Dale. *Classical approaches to natural language processing*, pages 3–8. 01 2010.
- [5] OpenAI. Openai api, 2020. URL <https://openai.com/blog/openai-api/>.
- [6] Python Software Foundation. python, 2021. URL <https://www.python.org/>.
- [7] Google Brain Team. tensorflow, 2019. URL <https://www.tensorflow.org/>.
- [8] Team NLTK. Natural language processor toolkit, 2021. URL <https://www.nltk.org/>.